

JAGS 20 mil e Stan 2 mil: comparação no mesmo caso

Experimento de 1 de outubro de 2026. Dados D.C. 2010, 143 unidades. Preserva A, estuda D e compara D entre JAGS e Stan. Não é uma nova estimação para o Brasil nem uma validação inferencial do modelo.

1. Pergunta e protocolo

A hipótese proposta pelo usuário é que JAGS necessita de cadeias mais longas, enquanto 2 mil amostras por cadeia podem ser suficientes em Stan. Esta rodada testa essa possibilidade, sem pressupor que o número nominal de iterações determine a precisão.

A é o qbl literal, mantido byte a byte. D é a alternativa multinomial experimental, com as mesmas prioris hierárquicas compartilhadas, mas sem as contagens auxiliares binomiais de A. A versus D é sensibilidade ao modelo. D/JAGS versus D/Stan compara o mesmo alvo posterior, sujeito à verificação numérica e aos diagnósticos de cada algoritmo.

JAGS: quatro cadeias, 1.000 iterações de adaptação, 5.000 de aquecimento e 20.000 retidas por cadeia. Stan: quatro cadeias, 2.000 de aquecimento e 2.000 retidas por cadeia, `adapt_delta=0,99` e profundidade máxima 12. `Thin=1`. As cadeias são processadas serialmente em ambos os casos. Há limite externo de 3.600 segundos por processo e nenhuma repetição automática.

As rodadas JAGS de 2 mil e 20 mil reutilizam dados, inicializações e sementes; não são replicações independentes. O ajuste Stan usa semente-base 1001261 com identificadores de cadeia 1 a 4. Os processos intensivos do experimento foram separados para não contaminar os relógios. Desenvolvimento e leitura estática ocorreram em paralelo; não se presume controle de todos os demais aplicativos do computador.

Durante esta execução, o usuário determinou que as próximas rodadas usem cadeias em paralelo e mais núcleos sempre que possível. A instrução foi registrada em `CLAUDE.md` e `future_parallel_chains.md`. Esta rodada serial não foi reiniciada nem teve o protocolo alterado; portanto, seus relógios não estimam diretamente o desempenho futuro com quatro cadeias concorrentes.

Stan integra a classe discreta usando a soma das três verossimilhanças ponderadas, em escala logarítmica. A parametrização não centrada preserva as seis variâncias com prior $\text{Exp}(5)$, usando raiz quadrada para os desvios-padrão. Os pesos são $(1, r_2, r_3)/(1+r_2+r_3)$, com r_2 e r_3 uniformes independentes: essa é a prior efetiva do esquema auxiliar ordenado de JAGS, não uma Dirichlet flat nem uma ordenação total entre as classes 2 e 3.

Uma classe posterior condicional é reconstruída por unidade e draw; essa mesma classe determina probabilidades e funcionais M/S. Médias Rao-Blackwellizadas, que integram também essa reconstrução, ficam em resultados secundários separados. Nenhuma alteração de prior foi usada como solução para dificuldades de mistura.

2. Tempos e critérios computacionais

Tabela 1. Relógios de parede por execução, em segundos, e diagnósticos dos 23 alvos globais. Geração inclui o processo completo e gravação dos draws. A compilação JAGS já está dentro desse processo; a compilação Stan é medida separadamente e somada uma única vez no total. O relógio de compilação Stan inclui a interface C++ de checagem de densidade e gradientes; outras verificações e tentativas de desenvolvimento ficam fora do tempo do ajuste. Total = geração + diagnóstico + essa compilação Stan, quando aplicável. As duas primeiras linhas são o piloto histórico preservado.

Uma primeira tentativa de diagnóstico Stan falhou em 11,43 s por despacho S3: `as.matrix()` sobre `draws_array` concatenava as cadeias quando o namespace posterior estava carregado. A correção converte apenas a representação local para arrays básicos, sem mudar valores, ordem, critérios ou o fit. A falha foi preservada em `stan_diagnostics01`; o diagnóstico válido está em `stan_diagnostics02`. Esse tempo de tentativa malsucedida, assim como desenvolvimento e QA, não integra o total produtivo da tabela; não houve nova amostragem.

Rodada	Geração (s)	Diagnóstico (s)	Total (s)	R-hat máximo	ESS mínimo bulk/cauda
A_JAGS_2k	102,57	22,35	124,92	3,451	4,4 / 4,0
D_JAGS_2k	68,25	21,72	89,97	2,472	4,8 / 5,0
A_JAGS_20k	385,84	206,70	592,54	3,097	4,5 / 5,3
D_JAGS_20k	261,65	202,61	464,26	1,518	7,4 / 11,2
D_Stan_2k	2.030,23	52,52	2.125,92	2,693	4,7 / 18,1

R-hat é um diagnóstico de concordância entre cadeias. ESS é o tamanho efetivo da amostra, distinto do número nominal de draws. Exigem-se $R\text{-hat} < 1,01$ e $ESS\text{ bulk e cauda} \geq 400$ para todos os alvos obrigatórios; as classificações têm também limite prospectivo de discrepância entre cadeias. Estatísticas indefinidas não recebem aprovação automática, mas sua indefinição isolada tampouco demonstra não convergência.

Tabela 2. Falhas dos critérios prospectivos. A coluna de indefinidos é subconjunto das falhas, não um grupo a somar. Falhas globais e locais são separadas dos indicadores de classes raras no CSV `diagnostic_groups.csv`.

Rodada	Globais reprovados / 23	Obrigatórios reprovados	Obrigatórios totais	Indefinidos
A_JAGS_2k	15	1.605	2.171	432
D_JAGS_2k	14	1.021	1.742	392
A_JAGS_20k	14	1.597	2.171	408
D_JAGS_20k	13	995	1.742	352
D_Stan_2k	10	1.024	1.742	420

A_JAGS_20k: execução e diagnóstico completos = TRUE; status = `computationally_inconclusive`.

D_JAGS_20k: execução e diagnóstico completos = TRUE; status = `computationally_inconclusive`.

D_Stan_2k: execução e diagnóstico completos = TRUE; status = `computationally_inconclusive`.

D/Stan, grupo global: 10 de 23 alvos reprovados, incluindo 0 indefinidos. R-hat máximo finito 2,6928; ESS mínimos bulk/cauda 4,7 / 18,1.

D/Stan, grupo local_continuous: 582 de 1.287 alvos reprovados, incluindo 0 indefinidos. R-hat máximo finito 1,8802; ESS mínimos bulk/cauda 5,7 / 16,5.

D/Stan, grupo class_count: 3 de 3 alvos reprovados, incluindo 2 indefinidos. R-hat máximo finito 2,2642; ESS mínimos bulk/cauda 5,1 / 18,9.

D/Stan, grupo class_indicator: 429 de 429 alvos reprovados, incluindo 418 indefinidos. R-hat máximo finito 2,8218; ESS mínimos bulk/cauda 4,6 / 29,6.

Tabela 3. Diagnósticos específicos de Hamiltonian Monte Carlo (HMC). Exigem-se zero divergências, zero atingimentos da profundidade máxima e E-BFMI $\geq 0,3$ em cada cadeia. E-BFMI mede a exploração da distribuição de energia. Os 860 parâmetros internos da parametrização não centrada recebem também os critérios R-hat/ESS, separadamente dos alvos comuns.

Cadeia	Divergências	Profundidade máxima atingida	E-BFMI
1	0	0	0,916
2	0	0	0,880
3	0	0	0,588
4	0	0	0,827

Crítérios HMC atendidos: TRUE. Parâmetros internos reprovados: 291 de 860. A precisão dos resultados comuns continua sujeita à Tabela 2; bom comportamento HMC não dispensa esses controles.

3. Comparação descritiva entre engines

Os resumos seguintes descrevem draws, não eventos eleitorais observados. π são pesos de mistura. $M=N(1-\tau)m$ e $S=N \tau(1-\nu)s$ representam transferências esperadas no mecanismo estatístico: τ é participação inicial, ν é preferência inicial pelo candidato focal, m e s são intensidades da classe latente. As somas são feitas dentro de cada draw conjunto, preservando dependência.

Tabela 4. D no mesmo alvo: médias amostrais JAGS 20 mil versus Stan 2 mil. A última coluna divide a diferença Stan-JAGS pela raiz da soma dos quadrados dos erros-padrão Monte Carlo (MCSE). É descritiva, não um teste de equivalência; MCSE não é uma referência confiável se a exploração posterior falhou.

Funcional	JAGS 20 mil	Stan 2 mil	Diferença	Diferença / MCSE combinado
$\pi[1]$	0,9748	0,5706	-0,4042	-12,57
$\pi[2]$	0,0182	0,4225	0,4043	12,59
$\pi[3]$	0,0071	0,0069	-0,0001	-1,53
M_{total}	382,7	4.807,8	4.425,1	8,76
S_{total}	106,5	9.525,1	9.418,6	3,67

Tabela 5. Médias de M e S por cadeia nas novas rodadas. Diferenças persistentes entre cadeias são importantes mesmo quando uma média agregada parece plausível. Estes valores não são contagens comprovadas de fraude.

Rodada / funcional	Cadeia 1	Cadeia 2	Cadeia 3	Cadeia 4
A_{JAGS_20k} / M_{total}	896,2	0,0	0,0	135,4
A_{JAGS_20k} / S_{total}	260,8	0,0	0,0	17,2
D_{JAGS_20k} / M_{total}	247,9	780,8	36,7	465,4
D_{JAGS_20k} / S_{total}	54,5	199,3	5,0	167,1
D_{Stan_2k} / M_{total}	3.451,0	4.458,4	5.478,1	5.843,7

Rodada / funcional	Cadeia 1	Cadeia 2	Cadeia 3	Cadeia 4
D_Stan_2k / S_total	7.788,0	15.225,0	1.978,2	13.109,1

4. Alcance e próximos passos

O número de iterações deve ser julgado pela precisão obtida, não pela reputação da engine. Tempos e ESS por segundo somente sustentam uma comparação de eficiência nos alvos cuja precisão esteja demonstrada. Este experimento não decide que uma prior é errada a partir de dificuldade de amostragem e não trata a execução JAGS anterior como prova suficiente de convergência.

A implementação Stan preserva o alvo, mas combina HMC, parametrização não centrada e marginalização das classes e da escala auxiliar dos pesos. Assim, uma diferença de desempenho se refere a essas implementações completas; não identifica isoladamente o efeito de trocar Gibbs por HMC.

A permanece preservada, com seus limites de suporte já documentados. D corrige o suporte conjunto por construção, mas ainda requer estudo de identificação, heterogeneidade legítima, recuperação em dados sintéticos e replicação externa com referência numérica dos autores. Esses requisitos científicos não são resolvidos apenas por cadeias mais longas ou HMC.

Nenhum gate histórico foi retroativamente aprovado. G3 permanece inconclusivo e G10 continua pendente de replicação numérica externa. Não houve nova estimação brasileira, mudança de filtros dos dados ou adoção de engine de produção. Os dados D.C. usam $A=NVoters-NValid$ na codificação dos autores; não se deve transportar esse denominador automaticamente para abstenção no Brasil.

O próximo passo deve partir do diagnóstico observado nesta rodada: distinguir dificuldades globais/loais de indicadores discretos raros, examinar a geometria e as cadeias preservadas e definir qualquer nova intervenção prospectivamente. Depois da validação do alvo e da replicação externa, retomar o caso brasileiro aprovado e os gates de escala/ingestão de 2026.

5. Fontes e reprodução

Ferrari, Diogo; McAlister, Kevin; Mebane, Walter R., Jr.; Wu, Patrick Y. (2019). eforensics 0.0.4. Commit 3017de537450f97a01872d0157462a68bea348ee. Vignette Introduction to eforensics, 16/08/2019; dados D.C. 2010. [Repositório dos autores](#). Snapshot local preservado. D é uma derivação experimental deste projeto, não uma implementação publicada pelos autores.

Mebane, Walter R., Jr. (2023). Lost Votes and Posterior Multimodality in the eforensics Model. PolMeth 2023, Stanford, 9-11 de julho; versão de 2 de julho de 2023. [Texto do autor](#).

Vehtari, Aki; Gelman, Andrew; Simpson, Daniel; Carpenter, Bob; Bürkner, Paul-Christian (2021). Rank-Normalization, Folding, and Localization: An Improved R-hat for Assessing Convergence of MCMC (with Discussion). Bayesian Analysis, 16(2), 667-718. [DOI 10.1214/20-BA1221](#).

Stan Development Team. Stan User's Guide: Latent Discrete Parameters; Diagnostics and Warnings. [Marginalização e diagnósticos](#), consultados em 01/10/2026. A documentação web consultada é atual; a engine instalada e usada é CmdStan 2.37.0, via cmdstanr 0.9.0.

Cálculos: R/experimental/mebane_ad_long/compare_engines.R, a partir dos diagnósticos persistidos. Apresentação: R/experimental/mebane_ad_long/write_report.R. Renderizador PDF preservado do estudo anterior. Contrato, revisão, fontes, dados e resultados estão vinculados pelos manifestos desta rodada; draws/CSV grandes e binários permanecem localmente preservados, sem excluir artefatos históricos nem instalar pacotes.